

ProjetoFinal

December 9, 2023

1 Desenvolvimento de rede neural artificial para predição de defeitos em motor redutor

Equipe: Raul Bernardo de Pontes Pires;

Wellyosn Carlos Pontes da Silva.

O objetivo central deste projeto é criar uma rede neural dedicada à previsão de falhas em motores por meio da análise de áudio. Inicialmente, realizamos a coleta de áudios do motor em pleno funcionamento e em perfeitas condições. Posteriormente, o motor foi submetido a uma série de problemas, e os áudios foram coletados novamente.

Com a base de áudios em mãos, iniciamos o processo de desenvolvimento da rede neural. O primeiro passo é a padronização dos dados, seguindo o seguinte fluxo:

1. Aplicação da Transformada Rápida de Fourier (FFT) em cada áudio.
2. Correlação dos 5 maiores picos da FFT de cada áudio.
3. Armazenamento desses dados em uma tabela CSV.

Para facilitar esse processo, foi desenvolvido um sistema que percorre a pasta *audios*. Essa pasta contém subpastas correspondentes a cada tipo de defeito ao qual o motor foi submetido. O sistema entra em cada subpasta, aplica o fluxo mencionado anteriormente e preenche a tabela CSV com as informações relevantes.

1.1 Aquisição dos dados

- Instalando algumas das bibliotecas que serão utilizadas no projeto.

```
[ ]: import os
import numpy as np
import librosa as lib
import csv
import pandas as pd
from scipy.stats import kurtosis
```

- Vamos criar uma variável chamada *pasta_principal* que armazenará a String relativa ao local onde os audios serão depositados;
- Vamos criar também uma variável (*resultados_por_audio*) que será responsável de armazenar os dados relativos a criação da tabela CSV.

```
[ ]: pasta_principal = "audios"

resultados_por_audio = []
```

Aqui está o código em que percorremos todas as subpastas da pasta *audios*, entrando em cada uma e iterando sobre todos os áudios presentes. Durante esse processo, a variável *resultados_por_audio* é preenchida com informações relevantes:

- **Objetivo:** Armazenar os 5 maiores valores (frequência e amplitude) da FFT de cada áudio.
- **Inclusões na variável *resultados_por_audio*:**
 - Nome do arquivo.
 - Tipo de defeito (correspondente ao nome da subpasta).
 - Valores de desvio padrão, Kurtosis e RMS.

```
[ ]: for subpasta in os.listdir(pasta_principal):
    caminho_subpasta = os.path.join(pasta_principal, subpasta)

    if os.path.isdir(caminho_subpasta):
        arquivos_audios = [f for f in os.listdir(caminho_subpasta) if f.
↪endswith(".wav")]

        for arquivo_audio in arquivos_audios:
            caminho_audio = os.path.join(caminho_subpasta, arquivo_audio)
            sinal, fs = lib.load(caminho_audio)
            sinal = sinal[:5 * fs]
            n = len(sinal)
            janela = np.hamming(n)
            sinal_janelado = janela * sinal
            Y = np.abs(np.fft.fft(sinal_janelado)) / n
            frequencias = np.linspace(0, fs / 2, n // 2)

            std_dev = np.std(sinal)
            kurt = kurtosis(sinal)
            rms = np.sqrt(np.mean(sinal**2))

            frequencias = frequencias[:n // 2]
            amplitudes = Y[:n // 2]

            indices_maiores = np.argsort(amplitudes)[::-1][:5]

            resultados_por_audio.append({
                "Defeito": subpasta,
                "DesvioPadrão": std_dev,
                "Kurtosis": kurt,
                "rms": rms,
                "CincoMaioresPontos": [(frequencias[i], amplitudes[i]) for i in
↪indices_maiores]
            })
```

De posse da variável `resultados_por_audio` já povoada, podemos então criar a tabela CSV.

```
[ ]: with open('resultados.csv', 'w', newline='') as csvfile:
    colunas = ["defeito", "desvio_padrao", "kurtosis", "rms", "frequencia_1",
    ↪ "amplitude_1", "frequencia_2", "amplitude_2", "frequencia_3", "amplitude_3",
    ↪ "frequencia_4", "amplitude_4", "frequencia_5", "amplitude_5"]
    csv_writer = csv.DictWriter(csvfile, fieldnames=colunas)
    csv_writer.writeheader()

    for resultado in resultados_por_audio:
        linha = {"defeito": resultado["Defeito"], "desvio_padrao":
    ↪ resultado["DesvioPadrão"], "kurtosis": resultado["Kurtosis"], "rms":
    ↪ resultado["rms"]}
        for i, ponto in enumerate(resultado["CincoMaioresPontos"], start=1):
            linha[f"frequencia_{i}"] = ponto[0]
            linha[f"amplitude_{i}"] = ponto[1]
        csv_writer.writerow(linha)

print("Resultados foram escritos no arquivo CSV: resultados.csv")
```

Resultados foram escritos no arquivo CSV: resultados.csv

Por fim, podemos plotar os 10 primeiros itens da tabela.

```
[ ]: resultados = pd.read_csv("resultados.csv")
resultados.head(10)
```

```
[ ]:      defeito  desvio_padrao  kurtosis      rms  frequencia_1  amplitude_1 \
0  Sobrecarga9      0.041385  1.032346  0.041385    968.617571    0.002954
1  Sobrecarga9      0.040538  1.302957  0.040538    970.417604    0.002844
2  Sobrecarga9      0.040352  1.078663  0.040352    968.617571    0.002600
3  Sobrecarga9      0.040512  1.052567  0.040512    969.217582    0.002811
4  Sobrecarga9      0.041496  0.955755  0.041496    676.012263    0.002802
5  Sobrecarga9      0.041655  0.907838  0.041655    970.217600    0.002968
6  Sobrecarga9      0.040544  1.091199  0.040544    675.612256    0.002331
7  Sobrecarga9      0.039735  1.271067  0.039735    970.417604    0.002597
8  Sobrecarga9      0.040676  1.198556  0.040676    970.217600    0.002373
9  Sobrecarga9      0.040883  1.073248  0.040883    675.212249    0.002650

      frequencia_2  amplitude_2  frequencia_3  amplitude_3  frequencia_4 \
0    675.212249    0.002345    675.012245    0.002234    968.817575
1    676.412271    0.001894    676.212267    0.001846    970.217600
2    675.012245    0.002581    675.212249    0.001965    1086.019701
3    675.612256    0.002451    675.412252    0.002359    1086.619712
4    969.817593    0.002314    970.017597    0.002134    823.014930
5    676.212267    0.002879    823.214934    0.002061    703.212757
6    969.217582    0.002320    998.618116    0.001815    381.806926
7    676.412271    0.001876    676.212267    0.001689    999.818137
```

8	676.212267	0.001882	970.017597	0.001715	735.013334
9	968.617571	0.002413	968.817575	0.002012	675.012245

	amplitude_4	frequencia_5	amplitude_5
0	0.001727	1086.019701	0.001690
1	0.001843	980.217782	0.001685
2	0.001687	381.606923	0.001662
3	0.001643	998.618116	0.001617
4	0.001693	702.812749	0.001656
5	0.001911	382.206933	0.001696
6	0.001693	675.412252	0.001667
7	0.001682	970.217600	0.001606
8	0.001709	972.617644	0.001675
9	0.001854	381.606923	0.001702

1.2 Padronização dos dados

Inicialmente vamos importar as libs para padronizar nossos dados, treinar e testar nossa rede neural.

```
[ ]: from sklearn.model_selection import train_test_split
from sklearn.preprocessing import StandardScaler
from sklearn.neural_network import MLPClassifier
from sklearn.metrics import confusion_matrix, accuracy_score, precision_score, recall_score, f1_score
import seaborn as sns
import matplotlib.pyplot as plt
```

No bloco de código abaixo, estamos realizando as etapas iniciais de preparação dos dados para o treinamento do modelo.

- **Leitura dos Dados:**
 - Utilizamos a biblioteca Pandas para ler os dados do arquivo *resultados.csv* e armazená-los na variável *data*.
- **Separação de Features e Rótulos:**
 - O próximo passo é dividir os dados em características (features) e rótulos. As características são armazenadas em *X*, enquanto os rótulos são armazenados em *y*. Isso é feito com base na estrutura do DataFrame, onde a coluna ‘defeito’ é excluída das características, sendo atribuída a *y*.
- **Divisão em Conjuntos de Treinamento e Teste:**
 - Utilizamos a função *train_test_split* da biblioteca scikit-learn para dividir nossos dados em conjuntos de treinamento e teste. Aqui, 80% dos dados são destinados ao treinamento (*X_train* e *y_train*), enquanto 20% são reservados para testes (*X_test* e *y_test*). O parâmetro *random_state* é fixado em 42 para garantir a reprodutibilidade dos resultados.

```
[ ]: data = pd.read_csv('resultados.csv')
X = data.drop('defeito', axis=1)
y = data['defeito']
```

```
X_train, X_test, y_train, y_test = train_test_split(X, y, test_size=0.2,
↪random_state=42)
```

Nesse momento podemos aplicar uma técnica importante de pré-processamento conhecida como escala padrão (`StandardScaler`).

- **Inicialização do Scaler:**
 - Criamos uma instância do `StandardScaler` da biblioteca `scikit-learn`, representada pela variável `scaler`.
- **Escalonamento das Features de Treinamento:**
 - Utilizamos o método `fit_transform` do `scaler` para calcular a média e o desvio padrão das features de treinamento (`X_train`) e, em seguida, escaloná-las. As features escalonadas são armazenadas em `X_train_scaled`.
- **Aplicação do Mesmo Escalonamento nas Features de Teste:**
 - Utilizamos o método `transform` do `scaler` para aplicar o mesmo ajuste de escala nas features de teste (`X_test`). As features escalonadas de teste são armazenadas em `X_test_scaled`.

O escalonamento é uma prática comum no pré-processamento de dados, especialmente quando lidamos com algoritmos sensíveis à escala das features, como aqueles baseados em distâncias. O `StandardScaler` assegura que as features tenham média zero e desvio padrão igual a um, contribuindo para um treinamento mais eficaz e robusto do modelo.

```
[ ]: scaler = StandardScaler()
X_train_scaled = scaler.fit_transform(X_train)
X_test_scaled = scaler.transform(X_test)
```

1.3 Treinamento

Agora podemos utilizar um classificador de redes neurais artificiais, implementado pelo `MLPClassifier` da biblioteca `scikit-learn`.

- **Definição do Modelo de Rede Neural:**
 - Criamos uma instância do `MLPClassifier` e configuramos alguns de seus parâmetros essenciais. No caso, estamos especificando duas camadas ocultas com 100 e 50 neurônios, respectivamente, através do argumento `hidden_layer_sizes`.
- **Configuração de Parâmetros Adicionais:**
 - Limitamos o número máximo de iterações de treinamento para 500 (`max_iter`) e fixamos a semente aleatória em 42 (`random_state`) para garantir reprodutibilidade.
- **Treinamento do Modelo:**
 - Utilizamos o método `fit` para treinar o modelo. Os dados de treinamento escalonados (`X_train_scaled` e `y_train`) são passados como argumentos para esse método.

Este trecho de código representa a criação, configuração e treinamento da rede neural artificial.

```
[ ]: model = MLPClassifier(hidden_layer_sizes=(100, 50), max_iter=500,
↪random_state=42)
model.fit(X_train_scaled, y_train)
```

```
[ ]: MLPClassifier(hidden_layer_sizes=(100, 50), max_iter=500, random_state=42)
```

1.4 Testes

Com a rede neural treinada, chegou o momento de utilizar o conjunto de testes para validação do modelo treinado. * **Previsão com Dados de Teste:** - Utilizamos o método `predict` do modelo (`model`) para gerar previsões com base nas features escalonadas de teste (`X_test_scaled`). As previsões são armazenadas na variável `y_pred`.

- **Construção da Matriz de Confusão:**

- Utilizamos a função `confusion_matrix` da biblioteca `scikit-learn` para comparar as previsões (`y_pred`) com os rótulos reais de teste (`y_test`). A matriz de confusão é armazenada na variável `conf_matrix`.

- **Impressão da Matriz de Confusão:**

- Por fim, exibimos a matriz de confusão no console por meio do comando `print`. A matriz de confusão é uma ferramenta essencial para avaliar o desempenho de um modelo de classificação, fornecendo insights sobre a precisão das previsões para cada classe.

Esse conjunto de instruções é fundamental para entender como o modelo se comporta em relação aos dados de teste e identificar possíveis áreas de melhoria ou ajuste. A análise da matriz de confusão é crucial para avaliar a performance em termos de verdadeiros positivos, verdadeiros negativos, falsos positivos e falsos negativos.

```
[ ]: y_pred = model.predict(X_test_scaled)
      conf_matrix = confusion_matrix(y_test, y_pred)
      print("Matriz de Confusão:")
      print(conf_matrix)
```

Matriz de Confusão:

```
[[25  0  0  0  6  0  0  0  0]
 [ 0 32  0  0  0  2  0  0  0]
 [ 0  0 32  0  0  0  0  0  0]
 [ 0  0  0 33  0  0  0  0  0]
 [ 4  0  0  0 20  0  0  0  0]
 [ 0  1  0  0  1 27  0  0  0]
 [ 0  0  0  0  0  0 29  0  0]
 [ 0  0  0  0  0  0  0 33  0]
 [ 0  0  0  0  0  0  0  0 26]]
```

1.5 Resultados

- **Acurácia (Accuracy):**

- A acurácia é uma métrica geral que mede a proporção de previsões corretas em relação ao total. Neste contexto, ela indica a precisão global do modelo em classificar corretamente os dados de teste.

- **Precisão (Precision):**

- A precisão é a razão de verdadeiros positivos sobre a soma de verdadeiros positivos e falsos positivos. Essa métrica é valiosa quando queremos garantir que as previsões positivas do modelo sejam confiáveis, minimizando os falsos positivos.

- **Revocação (Recall):**

- A revocação é a razão de verdadeiros positivos sobre a soma de verdadeiros positivos e falsos negativos. É crucial quando desejamos identificar a capacidade do modelo em

capturar todos os casos positivos, minimizando os falsos negativos.

- **F1-Score:**

- O F1-Score é uma média harmônica da precisão e da revocação. Essa métrica é particularmente útil quando há desequilíbrio entre as classes, pois oferece um equilíbrio entre a precisão e a revocação.

A impressão dessas métricas fornece uma visão abrangente do desempenho do modelo em várias dimensões. Interpretar essas métricas em conjunto permite uma avaliação mais completa e ajuda na identificação de possíveis áreas de melhoria ou ajuste no modelo de classificação.

```
[ ]: accuracy = accuracy_score(y_test, y_pred)
precision = precision_score(y_test, y_pred, average='weighted')
recall = recall_score(y_test, y_pred, average='weighted')
f1 = f1_score(y_test, y_pred, average='weighted')

print(f'Acurácia do modelo: {accuracy}')
print(f'Precisão do modelo: {precision}')
print(f'Revocação do modelo: {recall}')
print(f'F1-Score do modelo: {f1}')
```

```
Acurácia do modelo: 0.948339483394834
Precisão do modelo: 0.9500797515812149
Revocação do modelo: 0.948339483394834
F1-Score do modelo: 0.9488356999461126
```

- **Criação da Figura com Seaborn e Matplotlib:**

- Utilizamos o `plt.figure(figsize=(8, 6))` para definir o tamanho da figura que irá conter a matriz de confusão. Em seguida, empregamos `sns.heatmap` para criar a visualização da matriz.

- **Parâmetros do Heatmap:**

- O argumento `annot=True` adiciona os valores reais da matriz nas células, enquanto `fmt='d'` formata esses valores como inteiros. O `cmap='Blues'` define o esquema de cores azuis para a visualização.

- **Rótulos e Título:**

- `xticklabels` e `yticklabels` são configurados para exibir os rótulos das classes ao longo dos eixos x e y, respectivamente. O título 'Matriz de Confusão' é adicionado para contextualizar a visualização.

- **Exibição do Heatmap:**

- Finalmente, `plt.show()` é utilizado para exibir a visualização completa da matriz de confusão.

A Matriz de Confusão fornece uma representação gráfica das previsões do modelo em relação aos rótulos reais. Cada célula mostra o número de instâncias classificadas corretamente ou incorretamente para cada classe. Essa visualização é valiosa para entender quais classes o modelo confunde com mais frequência e onde pode haver oportunidades de melhoria.

```
[ ]: plt.figure(figsize=(8, 6))
sns.heatmap(conf_matrix, annot=True, fmt='d', cmap='Blues', xticklabels=model.
↪classes_, yticklabels=model.classes_)
```

```
plt.title('Matriz de Confusão')
plt.xlabel('Previsão')
plt.ylabel('Real')
plt.show()
```

